

PROYECTO DE FIN DE PARCIAL — SEGUNDO PARCIAL

Redes Neuronales y Aprendizaje Profundo · Transfer Learning · Fine-Tuning · Adaptación de Dominio

Modalidad	Grupal — 5 a 6 integrantes
Entregable	Notebook .ipynb + Informe PDF (máx. 12 páginas)
Puntaje total	10 puntos
Libertad	Cada grupo elige su propio problema, dataset y arquitectura — dentro de los temas del parcial
Repositorio	Subir a GitHub y compartir el enlace con la entrega

1. Descripción del proyecto

El proyecto del segundo parcial consiste en **adaptar un modelo pre-entrenado** a un problema concreto mediante transfer learning, fine-tuning, SFT o adaptación de dominio, según la arquitectura elegida. A diferencia del primer parcial, cada grupo tiene libertad de elegir el problema, el dataset y la arquitectura. Sin embargo, la metodología, la estructura del entregable y los criterios de evaluación son los mismos.

✓ Pueden elegir	Cualquier problema que involucre adaptar un modelo pre-entrenado: clasificación, generación, traducción, resumen, detección de anomalías, síntesis de imágenes, etc.
✓ Pueden elegir	Cualquier arquitectura vista en el parcial: Transformer (T5, FLAN-T5, BERT), LLM con LoRA/QLoRA, VAE, o GAN (DCGAN).
✓ Pueden elegir	Cualquier dataset público disponible en HuggingFace, Kaggle, UCI o repositorios oficiales de papers.
✗ No pueden	Usar arquitecturas no vistas en clase (CNN, ViT, Diffusion Models, etc.) sin autorización previa del docente.
✗ No pueden	Presentar un proyecto sin comparación cuantitativa del modelo base (sin adaptar) vs. el modelo adaptado.
✗ No pueden	Dos grupos del mismo curso trabajar sobre el mismo problema y dataset exacto.

Arquitectura	Estrategia equivalente al fine-tuning	Lo que constituye el "antes"
Transformer (T5, FLAN-T5)	Fine-tuning completo o PEFT (LoRA, prefix tuning)	Modelo base sin fine-tuning — evaluado con zero-shot prompting
LLM (Llama, GPT-2, TinyLlama)	LoRA / QLoRA / SFT sobre dataset de instrucciones o dominio específico	LLM base sin fine-tuning evaluado sobre el mismo dataset
AE / VAE	Transfer learning: pre-entrenar en dominio A, adaptar (fine-tunear) en dominio B	VAE pre-entrenado evaluado en dominio B sin adaptación (zero-shot)
GAN / DCGAN	Adaptación de dominio: continuar entrenamiento en nuevo dominio con LR reducido	GAN pre-entrenado generando imágenes del nuevo dominio sin adaptación (FID alto)

2. Requisito central: comparación antes vs. después

El argumento del proyecto debe responder a una pregunta concreta: **¿Cuánto mejora el modelo después de la adaptación respecto al modelo base sin adaptar?** Esta comparación es obligatoria y debe reportarse con métricas cuantitativas. Sin esta comparación, el proyecto no cumple el objetivo mínimo del segundo parcial.

Paso	Acción requerida	Resultado esperado
1	Seleccionar paper, problema y dataset	Paper donde la adaptación o fine-tuning sea la contribución central. Dataset público descargado con código.
2	Evaluar el modelo BASE sin fine-tuning	Métricas en el dataset elegido — este es el baseline obligatorio.
3	Aplicar fine-tuning / SFT / adaptación de dominio	Entrenamiento documentado: hiperparámetros, épocas, curvas de pérdida.
4	Evaluar el modelo FINE-TUNEADO	Mismas métricas sobre el mismo split de test.
5	Analizar y discutir la diferencia	¿Por qué mejoró? ¿Dónde sigue fallando? ¿Qué limitaciones tiene?

3. Estructura del entregable (igual que el primer parcial)

3.1 Notebook (.ipynb)

§ 1 — Paper y problema	Resumen del paper elegido (máx. 300 palabras): problema que resuelve, metodología de adaptación propuesta, métricas reportadas en el paper. Justificación de la elección.
§ 2 — Dataset	Carga del dataset con código. EDA: distribución de clases o samples, estadísticos descriptivos, visualizaciones. Explicar por qué este dataset es apropiado para el problema elegido.
§ 3 — Implementación de la adaptación / fine-tuning	Código limpio, comentado y reproducible. Arquitectura usada, hiperparámetros elegidos con justificación, estrategia utilizada (LoRA, full fine-tuning, freeze, adaptación de dominio, etc.).
§ 4 — Evaluación: antes y después	Tabla comparativa de métricas: modelo base vs. modelo fine-tuneado. Curvas de pérdida por época. Ejemplos cualitativos de predicciones antes y después.
§ 5 — Análisis crítico	¿La mejora es significativa? ¿En qué casos sigue fallando el modelo fine-tuneado? ¿Por qué creen que la adaptación funciona en este problema? Propuesta concreta de mejora adicional.
§ 6 — Conclusiones	¿Coinciden los resultados con lo que el paper reporta? ¿Qué aprendieron del proceso de adaptación/fine-tuning? Reflexión sobre las limitaciones del enfoque elegido.

3.2 Informe PDF

Máximo 12 páginas. Misma estructura del notebook en prosa académica. Figuras y tablas numeradas y referenciadas. Citas en formato APA o IEEE. Declaración de uso de IA si aplica.

4. Rúbrica de evaluación — 10 puntos

Los criterios son los mismos del primer parcial, adaptados al contexto de transfer learning y fine-tuning. La nota es **grupal**. La defensa oral es **individual** y constituye la nota del examen.

Criterio	Pts.	Excelente — 100%	Suficiente — 60%	Insuficiente — 0%
1. Comprensión del paper	2	Resumen preciso del paper: problema, metodología de adaptación/fine-tuning, contribución y métricas originales. Justificación sólida de la elección del problema.	Resumen incompleto o superficial del paper. No explica claramente qué aporta la adaptación o fine-tuning en ese contexto.	Errores conceptuales graves, no se evidencia haber leído el paper, o no hay paper de referencia.
2. Implementación de la adaptación / fine-tuning	3	Código funcional, limpio y reproducible. La estrategia de adaptación (LoRA, full fine-tuning, freeze, dominio, etc.) está correctamente implementada y documentada con justificación de hiperparámetros.	Código funcional con errores menores o sin justificación de decisiones. Fine-tuning implementado pero con uso excesivo de abstracciones de alto nivel sin comprensión.	Código no ejecuta, adaptación no implementada, o implementación copiada sin adaptación al problema elegido.
3. Resultados: antes vs. después	2.5	Comparación cuantitativa clara con métricas apropiadas para el problema. Curvas de entrenamiento, tabla comparativa y ejemplos cualitativos. Mejora demostrable y bien contextualizada.	Métricas reportadas pero comparación incompleta. Falta el baseline (modelo sin adaptar) o los ejemplos cualitativos.	Sin comparación antes/después, métricas ausentes o incorrectas. No se puede verificar si la adaptación mejoró algo.
4. Análisis crítico	1.5	Discute por qué la adaptación funciona en este problema, identifica casos donde sigue fallando y propone una mejora concreta y fundamentada con evidencia experimental.	Menciona limitaciones de forma superficial o sin respaldo en los datos. Propuesta de mejora genérica.	Sin análisis crítico, conclusiones vacías o que no corresponden a los resultados obtenidos.
5. Informe y presentación	1	Redacción académica clara, estructura coherente con las 6 secciones, figuras numeradas, citas en APA/IEEE, declaración de IA si aplica. Máximo 12 páginas.	Estructura presente pero con redacción o citas con errores. Supera en 1-2 páginas el límite.	Sin estructura reconocible, sin citas, informe ilegible o supera en más de 2 páginas el límite.
TOTAL	10			

Nota de corte: Excelente = 100% del criterio · Suficiente = 60% · Insuficiente = 0%. Para notas intermedias, use criterio propio (ej. respuesta parcial con error menor = 80%). **Un proyecto sin comparación antes/después obtiene automáticamente 0 en el criterio 3.**

5. Rúbrica de la defensa oral — nota del examen

La defensa oral es **individual** y constituye la nota del examen. Duración sugerida: 8–12 minutos por estudiante. El estudiante debe compartir pantalla con el notebook durante la defensa. La nota de la defensa es **independiente** de la nota del proyecto.

Criterio	Pts.	Excelente	Suficiente	Insuficiente
1. Dominio del paper y del problema	3	Explica el problema elegido, por qué el fine-tuning o la adaptación es la solución apropiada y qué aporta el paper de referencia. Sin leer.	Explica el problema pero no puede detallar por qué el fine-tuning o la adaptación es apropiada o qué aporta el paper.	No puede explicar el paper ni justificar la elección del problema.
2. Comprensión de la adaptación implementada	3	Describe con precisión la estrategia de adaptación (hiperparámetros, capas entrenadas, función de pérdida) y justifica cada decisión.	Describe la estrategia a grandes rasgos pero no puede justificar las decisiones de diseño.	No puede explicar cómo funciona la estrategia de adaptación implementada en su proyecto.
3. Interpretación de resultados	2	Interpreta correctamente las métricas obtenidas, explica la mejora observada y los casos donde el modelo sigue fallando.	Recuerda las métricas pero no puede interpretar la mejora ni los errores del modelo.	No recuerda los resultados o no puede interpretar las métricas de su propio notebook.
4. Pensamiento crítico	2	Responde preguntas no ensayadas con razonamiento correcto. Reconoce las limitaciones del enfoque elegido.	Responde parcialmente preguntas fuera del guion del proyecto.	No puede responder preguntas de análisis o contradice los resultados reportados.
TOTAL	10			

6. Normas de entrega

1. El notebook debe ejecutarse de inicio a fin sin errores antes de ser entregado (*Restart & Run All*).
2. El paper de referencia debe ser de acceso público (arXiv, ACL Anthology, NeurIPS, CVPR, etc.).
3. El dataset debe descargarse con código en el notebook. No incluir archivos de datos que superen 50 MB en el repositorio.
4. Dos grupos no pueden trabajar sobre el mismo problema y dataset exacto. El docente asignará temas si hay conflicto.
5. Todo uso de IA debe declararse explícitamente en el informe. El análisis crítico y las conclusiones deben ser propias.
6. La defensa oral es individual y constituirá la nota del examen. Cualquier integrante puede ser preguntado sobre cualquier parte del proyecto.
7. Plagio o copia entre grupos resulta en calificación de cero para ambos grupos involucrados.